

**BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC NGOẠI NGỮ – TIN HỌC THÀNH PHỐ HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN**



MÔN HỌC: PHÂN TÍCH DỮ LIỆU KINH DOANH

ĐỀ TÀI:

**PHÂN TÍCH KHÁCH HÀNG VÀ DỰ ĐOÁN RỜI BỎ
(CUSTOMER SEGMENTATION & CHURN PREDICTION)
ỨNG DỤNG CHO HỆ THỐNG THƯƠNG MẠI ĐIỆN TỬ TRANG
SỨC**

Giáo viên hướng dẫn: ThS. Lê Thị Bảo Trân

Thành viên: [Nhóm 16]

Nguyễn Thị Yến Nhi – 23DH112468

TP. Hồ Chí Minh, tháng 08 năm 2026

LỜI CẢM ƠN

Trước hết, chúng em xin gửi lời tri ân sâu sắc đến **Trường Đại học Ngoại ngữ - Tin học Thành phố Hồ Chí Minh**, đặc biệt là khoa Công nghệ Thông tin vì đã tạo điều kiện thuận lợi cho chúng em có cơ hội tiếp cận và học tập môn Phân tích dữ liệu kinh doanh.

Chúng em xin bày tỏ lòng biết ơn chân thành đến cô **ThS. Lê Thị Bảo Trân**, người đã tận tâm giảng dạy, hướng dẫn và đồng hành cùng nhóm chúng em trong suốt quá trình thực hiện đồ án. Sự nhiệt huyết, tận tình và kiên nhẫn của cô không chỉ giúp chúng em hiểu sâu hơn về kiến thức chuyên môn mà còn rèn luyện cho chúng em kỹ năng tư duy, làm việc nhóm và cách tiếp cận vấn đề một cách khoa học. Những lời góp ý chân thành và sự hướng dẫn chi tiết của cô đã giúp chúng em hoàn thiện đồ án một cách tốt nhất.

Không chỉ là một người giảng viên tận tụy, cô còn là một người truyền cảm hứng, giúp chúng em thêm yêu thích và có động lực học tập, nghiên cứu. Những bài giảng sinh động, lời giải thích cặn kẽ, cũng như những chia sẻ kinh nghiệm thực tế của cô đã mang đến cho chúng em những bài học vô giá, không chỉ trong phạm vi môn học mà còn có giá trị trong suốt chặng đường học tập và làm việc sau này.

Chúng em vô cùng trân trọng công sức, tâm huyết và sự chỉ dạy của cô. Hy vọng rằng trong thời gian tới, nhóm sẽ tiếp tục nhận được sự hướng dẫn, chỉ bảo quý báu từ cô. Một lần nữa, chúng em xin gửi lời cảm ơn chân thành và kính chúc cô thật nhiều sức khỏe, thành công trong sự nghiệp giảng dạy và tiếp tục truyền đạt kiến thức đến nhiều thế hệ sinh viên tiếp sau này.

Mục lục

I. Giới thiệu	4
1. Mô tả doanh nghiệp	4
2. Mục tiêu kinh doanh	4
3. Vấn đề cần giải quyết.....	4
II. Nội dung.....	4
1. Mô tả bộ dữ liệu.....	4
2. Yêu cầu Data Cleaning	5
III. Phương pháp phân tích	6
1. Phân tích khám phá dữ liệu (EDA).....	6
2. Thiết kế Dashboard.....	7
3. Phân nhóm khách hàng (Clustering).....	7
4. Dự báo giá trị khách hàng (Linear Regression).....	7
5. Dự đoán khách hàng rời bỏ (Classification)	7
IV. Kết quả phân tích.....	8
1. Kết quả phân tích khám phá (EDA).....	8
2. Dashboard tổng quan khách hàng	9
3. Kết quả phân nhóm khách hàng (Clustering)	11
4. Kết quả dự đoán CLV và chi tiêu kỳ tiếp theo (Linear Regression).....	13
4.1. Dự đoán CLV ước tính	13
4.2. Dự đoán chi tiêu ước tính kỳ tiếp theo.....	14
5. Kết quả dự đoán khách hàng rời bỏ (Classification)	14
V. Kết luận.....	16
Tài liệu tham khảo (IEEE)	17

I. Giới thiệu

1. Mô tả doanh nghiệp

Doanh nghiệp được phân tích trong đề tài là một sàn thương mại điện tử chuyên kinh doanh trang sức (nhẫn, dây chuyền, vòng tay, lắc chân, bông tai, trang sức bộ) phục vụ khách hàng cá nhân tại thị trường Việt Nam, với đơn hàng ghi nhận trên nhiều tỉnh/thành thuộc cả ba miền Bắc - Trung - Nam. Hệ thống đã tích lũy dữ liệu hồ sơ và hành vi mua sắm của hàng nghìn khách hàng (giá trị đơn hàng, số lần mua trước đó, tần suất mua hàng, đánh giá, tình trạng đăng ký thành viên, thu nhập ước tính...), tuy nhiên doanh nghiệp vẫn chưa khai thác triệt để nguồn dữ liệu này để phân khúc khách hàng và dự đoán rời bỏ - đặc biệt quan trọng với ngành trang sức vì giá trị đơn hàng cao và chu kỳ mua lặp lại dài hơn nhiều ngành bán lẻ khác.

2. Mục tiêu kinh doanh

- Hiểu rõ chân dung và hành vi mua sắm của từng nhóm khách hàng để cá nhân hóa chiến dịch marketing và chương trình khách hàng thân thiết.
- Nhận diện nhóm khách hàng giá trị cao (VIP) để có chính sách chăm sóc, giữ chân phù hợp, tối ưu chi phí marketing cho các sản phẩm trang sức giá trị lớn.
- Dự đoán xu hướng chi tiêu và giá trị vòng đời khách hàng (CLV) nhằm lập kế hoạch doanh thu, tồn kho theo dịp lễ, cưới hỏi và các mùa cao điểm mua trang sức.
- Phát hiện sớm khách hàng có nguy cơ rời bỏ (churn) để triển khai chương trình giữ chân kịp thời, giảm thất thoát doanh thu.

3. Vấn đề cần giải quyết

Từ những mục tiêu trên, đề tài tập trung giải quyết 3 nhóm bài toán phân tích dữ liệu kinh doanh chính: (1) Phân khúc khách hàng (Customer Segmentation) dựa trên các chỉ số RFM (Recency – Frequency – Monetary) kết hợp CLV; (2) Dự báo giá trị tương lai của khách hàng bằng hồi quy tuyến tính (Linear Regression); (3) Dự đoán khả năng rời bỏ của khách hàng bằng mô hình phân loại (Classification), từ đó trả lời các câu hỏi kinh doanh cốt lõi mà ban lãnh đạo quan tâm.

Để thực hiện đề tài, nhóm sử dụng Python cùng các thư viện Pandas, NumPy để xử lý dữ liệu; Matplotlib, Seaborn để trực quan hóa; Scikit-learn để xây dựng các mô hình Machine Learning (KMeans, Linear Regression, Random Forest Classifier).

II. Nội dung

1. Mô tả bộ dữ liệu

- Tên bộ dữ liệu: `trang_suc_online_clean.csv` - dữ liệu hành vi và hồ sơ khách hàng mua trang sức trực tuyến, đã được bản địa hóa theo thị trường Việt Nam (đơn vị tiền tệ VND, tỉnh/thành, dịp mua, chất liệu trang sức đặc trưng của thị trường trong nước).
- Quy mô: 3.593 bản ghi khách hàng, 24 cột dữ liệu gốc, không có giá trị thiếu hay bản ghi trùng lặp (theo cả toàn bộ dòng và theo `customer_id`).
- Lưu ý: đây là dữ liệu dạng "ảnh chụp" (snapshot) - mỗi dòng là hồ sơ và giao dịch gần nhất của một khách hàng, không phải chuỗi giao dịch theo thời gian thực. Do đó nhóm xây dựng thêm các biến kỹ thuật (`clv_est_vnd`, `next_period_spend_est_vnd`) và nhãn Churn theo quy tắc nghiệp vụ (rule-based) để phục vụ bài toán Clustering, Regression và Classification.

Bảng dưới đây mô tả các biến gốc trong bộ dữ liệu và các biến kỹ thuật được nhóm xây dựng thêm:

Biến	Loại biến	Ý nghĩa
customer_id	Định tính (khóa)	Mã định danh khách hàng
age	Định lượng	Tuổi khách hàng (18-65)
gender	Định tính	Giới tính (Nam/Nữ)
province / region	Định tính	Tỉnh/thành và miền (Bắc/Trung/Nam)
jewelry_category	Định tính	Danh mục trang sức (Nhẫn, Dây chuyền, Vòng tay, Lắc chân, Bông tai, Trang sức bộ)
material / karat_purity	Định tính/Định lượng	Chất liệu (Bạc, Vàng 18K/24K, Vàng đính đá quý, Bạch kim) và tuổi vàng tương ứng
weight_grams	Định lượng	Khối lượng trang sức (gram)
has_gemstone	Định tính (nhị phân)	Có đính đá quý hay không
occasion	Định tính	Dịp mua (Cưới hỏi, Sinh nhật, Tự mua sắm, Quà tặng...)
purchase_amount_vnd	Định lượng	Giá trị đơn hàng gần nhất (VND)
estimated_monthly_income_vnd	Định lượng	Thu nhập hàng tháng ước tính của khách hàng (VND)
review_rating	Định lượng	Điểm đánh giá trải nghiệm (2,5-5,0)
membership_status	Định tính	Có đăng ký thành viên (Có/Không)
discount_applied / promo_code_used	Định tính	Có áp dụng giảm giá / mã khuyến mãi hay không
payment_method / shipping_type	Định tính	Phương thức thanh toán, hình thức giao hàng
purchase_channel	Định tính	Kênh mua (Online / Tại cửa hàng)
previous_purchases	Định lượng	Số lần mua trước đó (Frequency, 1-30)
frequency_of_purchases	Định tính (thứ tự)	Tần suất mua hàng theo mô tả (Hàng tuần...Hàng năm)
recency_proxy_days (gốc)	Định lượng	Khoảng cách trung bình ước tính giữa 2 lần mua (ngày), suy ra từ Frequency of Purchases
monetary_est_vnd (gốc)	Định lượng	Tổng chi tiêu ước tính = Purchase Amount × Previous Purchases (VND)
clv_est_vnd (kỹ thuật)	Định lượng	Giá trị vòng đời khách hàng ước tính (VND), điều chỉnh theo Membership Status và Review Rating
next_period_spend_est_vnd (kỹ thuật)	Định lượng	Chi tiêu ước tính kỳ tiếp theo (VND), suy ra từ Purchase Amount và tần suất mua ước tính
churn (kỹ thuật, nhãn)	Định tính (nhãn)	Nhãn rời bỏ xây dựng theo quy tắc nghiệp vụ (xem mục III.5) - biến mục tiêu phân loại

2. Yêu cầu Data Cleaning


Trước khi phân tích, dữ liệu được kiểm tra theo quy trình: (1) kiểm tra dữ liệu thiếu, (2) kiểm tra trùng lặp, (3) phát hiện ngoại lệ, (4) chuẩn hóa định dạng. Kết quả kiểm tra trên bộ dữ liệu thật:

Bước kiểm tra	Phát hiện	Cách xử lý
Dữ liệu thiếu (Missing values)	0 giá trị thiếu trên toàn bộ 24 cột	Không cần xử lý
Dữ liệu trùng lặp (Duplicates)	0 bản ghi trùng lặp (toàn bộ dòng và theo customer_id)	Không cần loại bỏ
Giá trị ngoại lệ (Outliers, IQR)	158 giá trị vượt ngưỡng IQR ở purchase_amount_vnd (đơn hàng cao cấp, vàng/đá quý khối lượng lớn); 192 giá trị vượt ngưỡng ở weight_grams; 0 ở previous_purchases	Giữ nguyên - đây là các đơn hàng trang sức cao cấp hợp lệ (nhẫn/vòng đính đá quý, bộ trang sức cưới), không phải lỗi nhập liệu
Chuẩn hóa dữ liệu	Tên cột dạng snake_case sẵn có; giá trị định tính đã ở dạng tiếng Việt chuẩn hóa	Không cần xử lý thêm, chỉ mã hóa one-hot khi đưa vào mô hình

Sau bước kiểm tra, toàn bộ 3.593 bản ghi khách hàng được giữ lại để phục vụ các bước phân tích tiếp theo.

III. Phương pháp phân tích

Phần này trình bày quy trình phân tích mà nhóm áp dụng, phỏng theo cấu trúc quy trình mẫu của môn học.



Hình 1. Quy trình phân tích dữ liệu.

Mô tả: Nhóm bắt đầu với việc chọn bộ dữ liệu khách hàng trang sức trực tuyến, xác định vấn đề kinh doanh cần giải quyết (phân khúc khách hàng, dự báo giá trị và dự đoán rời bỏ). Tiếp theo, nhóm tiến hành phân tích khám phá dữ liệu (EDA) để hiểu các thông tin cơ bản của bộ dữ liệu, từ đó đi sâu vào tìm hiểu dữ liệu và xác định các vấn đề chuyên sâu hơn - bao gồm làm sạch dữ liệu (Cleaning), xây dựng biến kỹ thuật, phân cụm khách hàng (Clustering), dự báo giá trị (Regression) và dự đoán rời bỏ (Classification). Sau mỗi vòng tìm hiểu sâu hơn, nhóm quay lại phân tích khám phá dữ liệu (EDA) thêm một lần nữa để kiểm chứng, trước khi tổng hợp và diễn giải kết quả để trả lời các câu hỏi kinh doanh đặt ra ban đầu.

1. Phân tích khám phá dữ liệu (EDA)

Nhóm thực hiện thống kê mô tả (trung bình, trung vị, độ lệch chuẩn, tứ phân vị) cho các biến định lượng; vẽ biểu đồ phân phối (histogram/KDE) cho tuổi, giá trị đơn hàng (VND), số lần mua trước đó, điểm đánh giá; tính ma trận tương quan Pearson giữa các biến để xác định mối liên hệ; đồng thời phân tích xu hướng giá trị đơn hàng theo danh mục trang sức (Nhẫn, Dây chuyền, Vòng tay, Lắc chân, Bông tai, Trang sức bộ) và theo dịp mua (Cưới hỏi, Sinh nhật, Tự mua sắm...).

2. Thiết kế Dashboard

Nhằm hỗ trợ doanh nghiệp theo dõi tình hình kinh doanh và đưa ra quyết định dựa trên dữ liệu, nhóm xây dựng Dashboard tổng quan với giao diện trực quan, giúp nhà quản lý nhanh chóng nắm bắt các chỉ số quan trọng cũng như xu hướng hành vi khách hàng. Dashboard được thiết kế gồm 05 thành phần chính:

- KPI tổng quan: Hiển thị các chỉ số cốt lõi gồm tổng số khách hàng, tổng chi tiêu ước tính (VND) và tỷ lệ khách hàng rời bỏ (Churn Rate), giúp đánh giá nhanh hiệu quả hoạt động kinh doanh.
- Phân tích khách hàng: Trực quan hóa tỷ lệ khách hàng rời bỏ theo khu vực (Bắc – Trung – Nam) và cơ cấu chi tiêu theo giới tính, từ đó hỗ trợ nhận diện các nhóm khách hàng mang lại giá trị cao và khu vực có nguy cơ rời bỏ lớn.
- Phân tích trải nghiệm khách hàng: Hiển thị phân phối điểm đánh giá (Review Rating) cùng tỷ lệ Churn theo trạng thái thành viên và việc áp dụng khuyến mãi, giúp đánh giá mức độ hài lòng cũng như hiệu quả của các chương trình chăm sóc khách hàng.
- Phân tích sản phẩm và địa lý: Thể hiện phân bố khách hàng theo tỉnh/thành hoặc khu vực, đồng thời phân tích cơ cấu danh mục và chất liệu trang sức được lựa chọn nhiều nhất, hỗ trợ doanh nghiệp định hướng chiến lược kinh doanh theo từng thị trường.
- Hỗ trợ ra quyết định: Dashboard cung cấp cái nhìn tổng quan về hoạt động kinh doanh, giúp doanh nghiệp theo dõi hiệu quả bán hàng, nhận diện xu hướng tiêu dùng, đánh giá hiệu quả marketing và làm cơ sở cho việc xây dựng các chiến lược chăm sóc khách hàng, tối ưu doanh thu và nâng cao hiệu quả quản trị.

3. Phân nhóm khách hàng (Clustering)

Vì dữ liệu gốc không có ngày giao dịch cụ thể (không tính được Recency thực) và không có tổng chi tiêu lũy kế theo thời gian, nhóm sử dụng các biến RFM thay thế sẵn có và xây dựng thêm: `recency_proxy_days`, `previous_purchases` (đóng vai trò Frequency), `monetary_est_vnd` (đóng vai trò Monetary), và `clv_est_vnd` (CLV ước tính, VND). Bốn biến này được chuẩn hóa (StandardScaler) trước khi đưa vào KMeans, chạy trên tập dữ liệu 3.593 khách hàng. Số cụm tối ưu K được xác định bằng phương pháp Elbow (khảo sát K từ 2 đến 7), từ đó chọn K=4 để đảm bảo các nhóm có ý nghĩa kinh doanh rõ ràng.

4. Dự báo giá trị khách hàng (Linear Regression)

Nhóm xây dựng hai mô hình hồi quy tuyến tính riêng biệt để trả lời hai bài toán dự báo: (1) dự đoán CLV ước tính (`clv_est_vnd`) - chỉ số giá trị dài hạn của khách hàng, với biến đầu vào gồm Age, Purchase Amount, Previous Purchases, Review Rating cùng các biến định tính mã hóa one-hot (Jewelry Category, Material, Discount Applied, Promo Code Used, Membership Status, Has Gemstone); và (2) dự đoán chi tiêu ước tính kỳ tiếp theo (`next_period_spend_est_vnd`) - suy ra từ Purchase Amount và tần suất mua hàng ước tính ($30/\text{recency_proxy_days}$) có cộng thêm nhiễu ngẫu nhiên để mô phỏng biến động thực tế, với biến đầu vào tương tự nhưng không đưa `recency_proxy_days` vào để tránh mô hình chỉ học lại đúng công thức tạo nhân. Dữ liệu được chia 80% huấn luyện / 20% kiểm tra; cả hai mô hình được đánh giá bằng MAE và R^2 .

5. Dự đoán khách hàng rời bỏ (Classification)


Nhãn churn được xây dựng theo quy tắc nghiệp vụ (rule-based labeling): khách hàng có tần suất mua thấp (Hàng năm/Nửa năm một lần), không đăng ký thành viên, điểm đánh giá thấp ($< 3,5$), không dùng mã giảm giá và không áp dụng ưu đãi sẽ có điểm rủi ro rời bỏ cao hơn (có cộng thêm nhiễu ngẫu nhiên để mô phỏng biến động thực tế); tỷ lệ churn trên tập 3.593 khách hàng là 26,0%. Mô hình Random Forest Classifier (`class_weight = balanced`) được huấn luyện

trên các biến Age, Purchase Amount, Previous Purchases, Review Rating, CLV ước tính và các biến định tính mã hóa one-hot (Jewelry Category, Material, Occasion, Payment Method, Shipping Type, Discount Applied, Promo Code Used, Membership Status, Gender, Has Gemstone) - không sử dụng trực tiếp Frequency of Purchases/recency_proxy_days làm biến đầu vào để tránh rò rỉ thông tin (data leakage). Mô hình được đánh giá qua Accuracy, Precision, Recall, F1-score và ma trận nhầm lẫn.

IV. Kết quả phân tích


1. Kết quả phân tích khám phá (EDA)

Bộ dữ liệu phân tích gồm 3.593 khách hàng. Độ tuổi khách hàng trải khá đều từ 18-65 (trung bình $\approx 41,5$ tuổi). Giá trị đơn hàng (purchase_amount_vnd) dao động từ 300.000 đến 75.326.000 VND (trung bình $\approx 12.714.150$ VND, trung vị $\approx 9.826.000$ VND) - phân phối lệch phải rõ rệt, phản ánh đặc thù ngành trang sức nơi đa số đơn hàng ở mức phổ thông nhưng có một tỷ lệ đơn hàng cao cấp (vàng 24K, trang sức đính đá quý, trang sức bộ) kéo giá trị trung bình lên cao. Số lần mua trước đó (Previous Purchases) từ 1-30 lần và điểm đánh giá (Review Rating) từ 2,5-5,0.




Hình 2. Phân phối độ tuổi, giá trị đơn hàng (VND), số lần mua trước đó và điểm đánh giá.

Ma trận tương quan cho thấy monetary_est_vnd và clv_est_vnd có tương quan gần như tuyệt đối (0,99 - đúng như kỳ vọng vì clv_est_vnd được tính trực tiếp từ monetary_est_vnd). Purchase Amount có tương quan khá mạnh với cả hai biến này ($\approx 0,75$) và với weight_grams (0,71 - đơn hàng nặng ký hơn thường có giá trị cao hơn). Previous Purchases tương quan trung bình với Monetary/CLV ($\approx 0,45$). Đáng chú ý, Age và Review Rating gần như không tương quan với các biến chi tiêu - cho thấy tuổi tác và mức độ hài lòng không quyết định giá trị chi tiêu trong bộ dữ liệu này, mà giá trị chi tiêu chủ yếu gắn với khối lượng/chất lượng sản phẩm và tần suất mua lặp lại.



Hình 3. Ma trận tương quan giữa các biến hành vi khách hàng.


Xét theo danh mục trang sức, giá trị đơn hàng trung bình có sự khác biệt rõ rệt: Trang sức bộ cao nhất ($\approx 32,4$ triệu VND), tiếp đến Vòng tay ($\approx 17,3$ triệu VND), Dây chuyền ($\approx 13,5$ triệu VND), Lắc chân ($\approx 11,3$ triệu VND), Nhẫn ($\approx 7,5$ triệu VND) và Bông tai thấp nhất ($\approx 5,6$ triệu VND) - phản ánh đúng thực tế trang sức bộ và vòng tay thường có khối lượng kim loại/đá quý lớn hơn. Ngược lại, giá trị đơn hàng trung bình theo dịp mua khá đồng đều (dao động 12,44 - 13,13 triệu VND giữa Lễ/Tết, Quà tặng gia đình, Tự mua sắm, Cưới hỏi, Sinh nhật và Quà tặng người yêu) - cho thấy danh mục sản phẩm là yếu tố phân hóa giá trị đơn hàng mạnh hơn dịp mua.



Hình 4. Giá trị đơn hàng trung bình theo danh mục trang sức và theo dịp mua.


2. Dashboard tổng quan khách hàng

Dashboard tổng hợp cho thấy trên 3.593 khách hàng: tổng chi tiêu ước tính (monetary_est_vnd) đạt khoảng 139,2 tỷ VND, CLV trung bình $\approx 39,7$ triệu VND/khách; tỷ lệ khách hàng có dấu hiệu rời bỏ ở mức 26,0%, khá đồng đều giữa 3 miền (25,3% - 27,1%). Nữ giới chiếm phần lớn chi tiêu ước tính (71,1%) so với nam giới (28,9%) - phù hợp đặc thù ngành trang sức. Tỷ lệ khách hàng đăng ký thành viên đạt khoảng 30,3%.



Hình 5. Dashboard tổng quan phân tích khách hàng (VND).


Dashboard hành vi & dịch vụ cho thấy sự khác biệt rõ rệt về tỷ lệ churn giữa khách hàng có và không đăng ký thành viên (12,5% so với 31,9%) và giữa khách hàng có/không áp dụng giảm giá (16,2% so với 33,2%) - đây là hai tín hiệu mạnh nhất phản ánh đúng quy tắc gán nhãn churn ở mục III.5. Phương thức thanh toán và hình thức giao hàng được sử dụng khá đồng đều, không có phương thức nào chiếm ưu thế tuyệt đối.



Hình 5b. Dashboard hành vi mua sắm & dịch vụ.

Dashboard khu vực & phân khúc sản phẩm bổ sung góc nhìn về phân bố địa lý và sản phẩm: TP. Hồ Chí Minh (427 khách hàng) và Hà Nội (334) dẫn đầu về số lượng khách hàng, tiếp theo


là Đà Nẵng (156); tỷ trọng chi tiêu ước tính giữa 3 miền tương đối cân bằng (Miền Nam 35,3%, Miền Bắc 34,1%, Miền Trung 30,5%). Nhẫn (880), Dây chuyền (754) và Bông tai (690) là các danh mục được mua nhiều nhất về số lượng, trong khi Vàng 18K (983) và Bạc (870) là hai chất liệu phổ biến nhất.



Hình 5c. Dashboard khu vực & phân khúc sản phẩm.

3. Kết quả phân nhóm khách hàng (Clustering)

Biểu đồ Elbow cho thấy độ giảm của Inertia chậm lại rõ rệt sau K=4, do đó nhóm chọn K=4 cụm cho mô hình KMeans cuối cùng.




Hình 6. Biểu đồ Elbow xác định số cụm tối ưu.

Kết quả phân cụm xác định được 4 nhóm khách hàng với đặc điểm và quy mô như sau (recency_proxy_days: số nhỏ = mua thường xuyên hơn; monetary_est_vnd/clv_est_vnd tính bằng VND):

Nhóm khách hàng	Số lượng	Tỷ lệ	Recency TB (ngày)	Prev. Purchases TB	Monetary TB (VND)	CLV TB (VND)
Khách hàng VIP (giá trị cao nhất)	399	11.1%	145	23.6	144.228.248	147.447.963
Khách hàng trung thành	1233	34.3%	89.7	21.8	38.776.480	39.911.824
Khách hàng có nguy cơ rời bỏ	631	17.6%	367	14.7	24.634.691	25.228.496
Khách hàng phổ thông / mới	1330	37%	88.4	7.6	13.756.080	14.031.194

Đồ thị khách hàng theo Previous Purchases và Monetary, tô màu theo cụm



Hình 7. Phân bố khách hàng theo Previous Purchases và Monetary (VND), tô màu theo cụm.

→ **Trả lời câu hỏi kinh doanh 1 – Có bao nhiêu nhóm khách hàng khác nhau?** Kết quả phân cụm xác định 4 nhóm khách hàng rõ rệt: khách hàng phổ thông/mới (37,0%), khách hàng trung thành (34,3%), khách hàng có nguy cơ rời bỏ (17,6% - nhóm này có recency proxy trung bình lên tới 367 ngày, tức chỉ mua khoảng 1 lần/năm) và khách hàng VIP (11,1%).


→ **Trả lời câu hỏi kinh doanh 2 – Khách hàng nào có giá trị cao nhất?** Nhóm Khách hàng VIP (cụm có Monetary và CLV trung bình cao nhất, lần lượt $\approx 144,2$ triệu VND và $\approx 147,4$ triệu VND/khách) là nhóm mang lại giá trị lớn nhất. Danh sách 5 khách hàng có CLV ước tính cao nhất như bảng dưới đây, đây là nhóm cần được ưu tiên chăm sóc và giữ chân:

Mã khách hàng	CLV ước tính (VND)	Monetary ước tính (VND)	Previous Purchases
2736	428.590.298	368.268.000	30
15	358.309.923	346.026.000	30
840	345.711.565	315.776.000	27
122	334.954.754	340.332.000	30
3004	328.013.414	278.544.000	19

4. Kết quả dự đoán CLV và chi tiêu kỳ tiếp theo (Linear Regression)

4.1. Dự đoán CLV ước tính

Mô hình hồi quy tuyến tính dự đoán CLV ước tính (VND) đạt hệ số xác định $R^2 \approx 0,808$ và sai số tuyệt đối trung bình $MAE \approx 13.649.347$ VND, cho thấy mô hình giải thích được khoảng 80,8% biến động CLV của khách hàng - mức độ phù hợp tốt, chủ yếu vì CLV được cấu thành trực tiếp từ Purchase Amount và Previous Purchases.




Hình 8. So sánh giá trị thực tế và giá trị dự đoán CLV ước tính (VND).

Phân tích hệ số hồi quy cho thấy tình trạng đăng ký thành viên và chất liệu trang sức có tác động mạnh nhất đến CLV:

Biến	Hệ số hồi quy (VND)	Chiều tác động
membership_status = Không	-7.213.587	Khách hàng không đăng ký thành viên → CLV thấp hơn ≈7,21 triệu VND so với có đăng ký
material = Vàng 18K	+4.371.794	Mua chất liệu Vàng 18K → CLV cao hơn ≈4,37 triệu VND so với Bạc (tham chiếu)
material = Vàng 24K	+4.276.917	Mua chất liệu Vàng 24K → CLV cao hơn ≈4,28 triệu VND so với Bạc (tham chiếu)
material = Bạch kim	+3.728.926	Mua chất liệu Bạch kim → CLV cao hơn ≈3,73 triệu VND so với Bạc (tham chiếu)
material = Vàng đính đá quý	+3.011.804	Mua chất liệu Vàng đính đá quý → CLV cao hơn ≈3,01 triệu VND so với Bạc (tham chiếu)
previous_purchases	+2.604.598 /lần	Mỗi lần mua trước đó thêm → CLV tăng ≈2,60 triệu VND

4.2. Dự đoán chi tiêu ước tính kỳ tiếp theo

Mô hình hồi quy thứ hai dự đoán chi tiêu ước tính kỳ tiếp theo (`next_period_spend_est_vnd`) đạt $R^2 \approx 0,252$ và $MAE \approx 8.281.899$ VND. Hệ số xác định thấp hơn nhiều so với mô hình CLV vì biến mục tiêu này phụ thuộc chủ yếu vào tần suất mua hàng (`recency_proxy_days`) - biến chủ động không đưa vào mô hình để tránh việc mô hình chỉ học lại đúng công thức tạo nhân thay vì học một quy luật dự báo thực sự; phần biến động còn lại chủ yếu đến từ nhiễu ngẫu nhiên mô phỏng. Đây là kết quả thực tế thường gặp khi dự báo chi tiêu ngắn hạn chỉ dựa trên hồ sơ khách hàng mà thiếu lịch sử giao dịch theo thời gian.



Hình 8b. So sánh giá trị thực tế và giá trị dự đoán chi tiêu kỳ tiếp theo (VND).


Hệ số hồi quy cho thấy danh mục sản phẩm và dịp mua hàng là các yếu tố có ảnh hưởng rõ nhất đến chi tiêu kỳ tiếp theo:

Biến	Hệ số hồi quy (VND)	Chiều tác động
<code>jewelry_category = Trang sức bộ</code>	+2.856.424	Mua Trang sức bộ → chi tiêu kỳ sau cao hơn $\approx 2,86$ triệu VND so với Bông tai (tham chiếu)
<code>jewelry_category = Vòng tay</code>	+1.600.482	Mua Vòng tay → chi tiêu kỳ sau cao hơn $\approx 1,60$ triệu VND so với Bông tai (tham chiếu)
<code>occasion = Quà tặng người yêu</code>	+1.168.793	Mua làm quà tặng người yêu → chi tiêu kỳ sau cao hơn $\approx 1,17$ triệu VND so với Cưới hỏi (tham chiếu)
<code>occasion = Tự mua sắm</code>	+950.662	Tự mua sắm → chi tiêu kỳ sau cao hơn $\approx 0,95$ triệu VND so với Cưới hỏi (tham chiếu)
<code>review_rating</code>	+719.221 /điểm	Điểm đánh giá tăng 1 điểm → chi tiêu kỳ sau tăng $\approx 0,72$ triệu VND
<code>jewelry_category = Dây chuyền</code>	+692.697	Mua Dây chuyền → chi tiêu kỳ sau cao hơn $\approx 0,69$ triệu VND so với Bông tai (tham chiếu)


5. Kết quả dự đoán khách hàng rời bỏ (Classification)

Mô hình Random Forest Classifier dự đoán khách hàng rời bỏ đạt Accuracy $\approx 72,5\%$, Precision $\approx 47,6\%$, Recall $\approx 58,3\%$ và F1-score $\approx 52,4\%$ trên tập kiểm tra. Recall cao hơn Precision cho

thấy mô hình có xu hướng phát hiện được phần lớn khách hàng thực sự rời bỏ, nhưng cũng cảnh báo nhầm một số khách hàng không rời bỏ; nhóm khuyến nghị cân nhắc điều chỉnh ngưỡng phân loại (threshold) nếu ưu tiên kinh doanh là tối đa hóa Precision để giảm chi phí chăm sóc sai đối tượng.



Hình 9. Ma trận nhầm lẫn của mô hình dự đoán churn.



Hình 10. Mức độ quan trọng của các biến trong mô hình dự đoán churn (Top 7).

Điểm đánh giá (review_rating) là biến quan trọng nhất trong việc dự đoán churn ($\approx 17,2\%$ tổng mức độ quan trọng), phù hợp với cách nhóm xây dựng quy tắc gán nhãn ở mục III.5. Bên cạnh đó, tình trạng thành viên ($\approx 11,6\%$), áp dụng giảm giá ($\approx 9,5\%$), CLV ước tính ($\approx 8,8\%$), mã khuyến mãi ($\approx 8,1\%$), giá trị đơn hàng ($\approx 8,0\%$) và tuổi khách hàng ($\approx 8,0\%$) cũng có mức đóng góp khá đồng đều, cho thấy mô hình dựa vào nhiều tín hiệu hành vi kết hợp hơn là chỉ tập trung vào 1-2 biến chỉ phối.

→ **Trả lời câu hỏi kinh doanh 3 – Khách hàng nào có nguy cơ rời bỏ?** Kết hợp cụm 'Khách hàng có nguy cơ rời bỏ' (631 khách hàng, recency proxy trung bình 367 ngày - chỉ mua khoảng 1 lần/năm) và xác suất churn dự đoán từ mô hình, nhóm xác định danh sách khách hàng giá trị cao nhưng có xác suất rời bỏ cao - đây là nhóm ưu tiên cao nhất cho chiến dịch giữ chân vì vừa có nguy cơ rời bỏ vừa mang lại giá trị lớn nếu được giữ lại:

Mã khách hàng	CLV ước tính (VND)	Xác suất rời bỏ	Previous Purchases	Điểm đánh giá
3356	51.650.905	80.1%	14	2.8
3013	5.505.043	79.0%	21	3.2
3016	32.628.202	78.5%	30	2.6
2713	51.090.650	78.2%	30	2.9
2820	72.500.856	77.3%	29	3

V. Kết luận

Qua quá trình phân tích bộ dữ liệu khách hàng trang sức trực tuyến trên 3.593 khách hàng, nhóm đã hoàn thành đầy đủ các bước: mô tả doanh nghiệp và bộ dữ liệu, kiểm tra làm sạch dữ liệu, xây dựng các biến kỹ thuật RFM/CLV/Churn, phân tích khám phá dữ liệu (EDA), xây dựng Dashboard tổng quan, phân cụm khách hàng bằng KMeans, dự báo CLV ước tính và chỉ tiêu kỳ tiếp theo bằng Linear Regression ($R^2 \approx 0,808$ và $R^2 \approx 0,252$) và dự đoán rời bỏ bằng mô hình phân loại Random Forest (Accuracy $\approx 72,5\%$).

Các kết quả chính đã trả lời được đầy đủ 3 câu hỏi kinh doanh đặt ra:

- Hệ thống có 4 nhóm khách hàng khác biệt rõ rệt: phổ thông/mới (37,0%), trung thành (34,3%), có nguy cơ rời bỏ (17,6%) và VIP (11,1%).
- Nhóm khách hàng VIP mang lại giá trị vòng đời ước tính cao nhất ($\approx 147,4$ triệu VND/khách), cần được ưu tiên chăm sóc.
- Mô hình phân loại đã xác định được danh sách khách hàng giá trị cao có xác suất rời bỏ trên 77%, chủ yếu là khách hàng có điểm đánh giá thấp và không đăng ký thành viên - đây là nhóm cần các chiến dịch giữ chân (khuyến khích đăng ký thành viên, khảo sát cải thiện trải nghiệm) triển khai sớm.
- Mô hình dự đoán chỉ tiêu kỳ tiếp theo đạt độ phù hợp thấp hơn nhiều ($R^2 \approx 0,252$) so với mô hình CLV, cho thấy chỉ tiêu ngắn hạn của khách hàng khó dự báo chính xác nếu chỉ dựa vào hồ sơ tính mà thiếu lịch sử giao dịch theo thời gian thực.

Hạn chế của đề tài: bộ dữ liệu sử dụng vẫn là dữ liệu dạng ảnh chụp (snapshot), không có lịch sử giao dịch theo thời gian thực, nên Recency, Monetary tích lũy, CLV, chỉ tiêu kỳ tiếp theo và nhãn Churn đều là các biến kỹ thuật được nhóm suy luận/xây dựng theo quy tắc nghiệp vụ chứ không phải số liệu quan sát trực tiếp. Kết quả mô hình vì vậy mang tính minh họa phương pháp luận hơn là một dự báo chính xác tuyệt đối cho một doanh nghiệp cụ thể.

Hướng phát triển tiếp theo của đề tài: (1) thu thập/bổ sung dữ liệu giao dịch có mốc thời gian thực để tính Recency và nhãn Churn chính xác hơn; (2) thử nghiệm thêm các thuật toán clustering khác (Hierarchical, DBSCAN) và các mô hình classification nâng cao (XGBoost, LightGBM), đồng thời hiệu chỉnh ngưỡng phân loại để cải thiện Precision/Recall theo mục tiêu kinh doanh; (3) triển khai mô hình dự đoán churn theo thời gian thực (real-time scoring) tích hợp vào hệ thống CRM của doanh nghiệp.

Tài liệu tham khảo (IEEE)

- [1] Pandas Development Team, "pandas documentation," 2024. [Trực tuyến]. Available: <https://pandas.pydata.org/docs/>.
- [2] Scikit-learn Developers, "scikit-learn: Machine Learning in Python," Journal of Machine Learning Research, vol. 12, pp. 2825-2830, 2011.
- [3] J. D. Hunter, "Matplotlib: A 2D graphics environment," Computing in Science & Engineering, vol. 9, no. 3, pp. 90-95, 2007.
- [4] M. Waskom, "seaborn: statistical data visualization," Journal of Open Source Software, vol. 6, no. 60, p. 3021, 2021.
- [5] P. Fader, B. Hardie, "RFM and CLV: Using Iso-value Curves for Customer Base Analysis," Journal of Marketing Research, vol. 42, no. 4, pp. 415-430, 2005.
- [6] L. Breiman, "Random Forests," Machine Learning, vol. 45, no. 1, pp. 5-32, 2001.